

## תרגיל 4 מבוא ללמידה חישובית

1.

(a)

נפתור את בעיית האופטימיזציה :

$$\arg \min_y ||x - y||$$

$$||y|| \leq R$$

ששקולה לבעיה הקמורה:

$$\operatorname{argmin}_y ||x - y||^2$$

$$||y||^2 \leq R^2$$

$$\mathcal{L}(y, \lambda) = ||x - y|| + \lambda (||y||^2 - R^2)$$

$$\frac{\partial \mathcal{L}(y, \lambda)}{\partial y} = 2(y - x) + 2\lambda y = 0 \Rightarrow y = \frac{x}{1 + \lambda}$$

בנוסף Complementary Slackness מתקיים:

$$\lambda (||y||^2 - R^2) = 0$$

אם  $\lambda = 0$ : מתקיים  $x = y$

$$||y|| = R \Rightarrow ||x|| = R(1 + \lambda) \Rightarrow \lambda = \frac{||x|| - R}{R} \Rightarrow y = \frac{R}{||x||} x$$

כלומר

$$\Pi_{\mathcal{K}}(x) = \begin{cases} x & ||x|| \leq R \\ \frac{R}{||x||} x & else \end{cases}$$

לכן

$$w_{t+1} = \begin{cases} w_t - \eta_t \nabla f_i(w_t) & ||w_t - \eta_t \nabla f_i(w_t)|| \leq R \\ \frac{R(w_t - \eta_t \nabla f_i(w_t))}{||w_t - \eta_t \nabla f_i(w_t)||} & else \end{cases}$$

נשים לב ש  $y_i w x_i > 1$  אז  $w_{t+1} = w_t$  אחרת  $w_{t+1} = w_t + y_i x_i$

כלומר נקבל עבור hinge loss

$$w_{t+1} = \begin{cases} w_t & y_i w x_i > 1 \\ w_t + y_i x_i & ||w_t + y_i x_i|| \leq R \\ \frac{R}{||w_t + y_i x_i||} (w_t + y_i x_i) & \text{else} \end{cases}$$

(b) תהי  $z \in \mathcal{K}$  אם  $y \in \mathcal{K}$  אז  $x = y$  לכן  $||y - z|| = ||x - z||$

אם  $y \notin \mathcal{K}$  אז הישרים  $x - z, y - x$  מאונכים מכיוון ש  $\Pi_{\mathcal{K}}(y) = x$  לכן המשולש המוגדר על ידי הנקודות  $x, y, z$  הוא ישר זווית ומתקיים שהישר  $y - z$  הוא היתר לכן מתקיים  $||y - z|| > ||x - z||$  כנדרש

(c) נעתיק את ההוכחה

#### 5.4. OPTIMIZATION ALGORITHMS

**Theorem 5.4.1.** Let  $\epsilon > 0$ . For  $w_1 = w' = 0$ ,  $\eta_t \equiv \frac{\epsilon}{G^2}$  and  $T = \frac{B^2 G^2}{\epsilon^2}$  we have that

$$f(\bar{w}) - f(w^*) \leq \epsilon$$

*Proof.* From the definition of convexity:

$$f(\bar{w}) \leq \frac{1}{T} \sum_{t=1}^T f(w_t)$$

Subtracting the optimal value from both sides, we have:

$$f(\bar{w}) - f(w^*) \leq \frac{1}{T} \sum_{t=1}^T f(w_t) - f(w^*)$$

From convexity,  $f(\cdot)$  lies above its tangent at the point  $w_t$ , and so:

$$f(\bar{w}) - f(w^*) \leq \frac{1}{T} \sum_{t=1}^T \langle \nabla f(w_t), w_t - w^* \rangle$$

For any two vectors  $u, v$  we have the property that  $\|u\|_2^2 - \|u - \eta v\|_2^2 = 2\eta \langle u, v \rangle - \eta^2 \|v\|_2^2$ . Setting  $u = w_t - w^*$ ,  $v = \nabla f(w_t)$ , while noting that  $u - \eta v = w_t - \eta \nabla f(w_t) - w^* =$

מתקיים  $w_{t+1} \in \mathcal{K}, w^* \in \mathcal{K}$  לפי סעיף קודם :

$$||w_t - \eta \nabla f(w_t) - w^*|| \geq ||w_{t+1} - w^*||$$

לכן נקבל

$$\begin{aligned} f(\bar{w}) - f(w^*) &\leq \frac{1}{T} \sum_{t=1}^T \frac{||w_t - w^*|| - ||w_t - w^* - \eta \nabla f(w_t)||}{2\eta} - \frac{\eta}{2} ||\nabla f(w_t)|| \\ &\leq \frac{1}{T} \sum_{t=1}^T \frac{||w_t - w^*|| - ||w_{t+1} - w^*||}{2\eta} - \frac{\eta}{2} ||\nabla f(w_t)|| \end{aligned}$$

$$\begin{aligned}
&= \frac{\|w_1 - w^*\|_2^2}{2\eta T} - \frac{\|w_{T+1} - w^*\|_2^2}{2\eta T} + \frac{\eta}{2} \frac{1}{T} \sum_{t=1}^T \|\nabla f(w_t)\|_2^2 \\
&\leq \frac{B^2}{2\eta T} + \frac{\eta G^2}{2} = \epsilon
\end{aligned}$$

2

נציב  $k = 2$

$$\begin{aligned}
f(w_1, w_2) &= \frac{\beta}{2} (||w_1||^2 + ||w_2||^2) + \ell(w_1, w_2, x_i, y_i) \\
&= \frac{\beta}{2} (||w_1||^2 + ||w_2||^2) + \frac{1}{2} \max_{j \in [2]} (w_j x_i - w_{y_i} x_i + 1(y_1 \neq j)) \\
&= \frac{\beta}{2} (||w_1||^2 + ||w_2||^2) + \frac{1}{2} \max(0, 1 - (2y_i - 3)(w_2 - w_1)x_i)
\end{aligned}$$

נבצע החלפת משתנים נסמן  $u = w_1 + w_2, v = w_2 - w_1$  נקבל

$$\frac{\beta}{2} \left( \left\| \frac{1}{2}(u - v) \right\|^2 + \left\| \frac{1}{2}(u + v) \right\|^2 \right) + \frac{1}{2} \max(0, 1 - y'_i u x_i), \quad y'_1 = 1, y'_2 = -1$$

$$\begin{aligned}
&\frac{\beta}{8} (||u - v||^2 + ||u + v||^2) + \frac{1}{2} \ell_{hinge}(u, x_i, y'_i) \\
&= \frac{\beta}{8} (||u||^2 - 2 \langle u, v \rangle + ||v||^2 + ||u||^2 + 2 \langle u, v \rangle + ||v||^2) \\
&+ \frac{1}{2} \ell_{hinge}(u, x_i, y'_i) = \frac{\beta}{4} (||v||^2 + ||u||^2) + \ell_{hinge}(u, x_i, y'_i)
\end{aligned}$$

נשים לב ש  $\ell_{hinge}(u, x_i, y'_i)$  לא תלויה ב  $v$  לכן המינימום של  $f(u, v)$  התקבל כאשר

$$v^* = 0 \text{ והפתרון האופטימלי הוא } \frac{\beta}{4} ||u^*|| + \ell_{hinge}(u^*, x_i, y'_i) \text{ לכן}$$

$$w^*(\beta') = u^*(\beta) = w_2^*(\beta) - w_1^*(\beta) \text{ and } \beta' = \frac{1}{2} \beta$$

.3

$$\begin{aligned}
&\min_{w, b, \xi} \frac{1}{2} w^T w + \frac{C}{2} \sum_{i=1}^m \xi_i^2 \\
&\text{s.t. } y_i(w^T x_i + b) \geq 1 - \xi_i \quad \forall i = 1, \dots, m
\end{aligned}$$

(a)

נראה שהאילוץ  $\forall i \xi_i \geq 0$  אינו משנה את הפתרון של בעיית האופטימיזציה כלומר נניח בשלילה שקיים פתרון אופטימלי כך ש  $\xi_{i_0} < 0$  אז

$$y_{i_0}(w^T x_{i_0} + b) \geq 1 - \xi_{i_0} \Rightarrow y_{i_0}(w^T x_{i_0} + b) > 1$$

לכן מצאנו פתרון פיזיבלי שמקטין את פונקציית המטרה בסתירה לכך שהפתרון שמקיים  $\xi_{i_0} < 0$

(b)

$$\mathcal{L}(w, b, \xi, \lambda) = \frac{1}{2} w^T w + \frac{C}{2} \sum_{i=1}^m \xi_i^2 + \sum_{i=1}^m \lambda_i (1 - y_i(w^T x_i + b) - \xi_i) =$$

$$\frac{1}{2} w^T w + \frac{C}{2} \sum_{i=1}^m \xi_i^2 + \sum_{i=1}^m \lambda_i (1 - y_i(w^T x_i + b)) - \langle \xi, \lambda \rangle$$

(c)

$$\nabla_w \mathcal{L} = w - \sum_{i=1}^m \lambda_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^m \lambda_i y_i x_i$$

$$\nabla_b \mathcal{L} = \sum_{i=1}^m \lambda_i y_i = 0$$

$$\nabla_\xi \mathcal{L} = C\xi - \lambda = 0 \Rightarrow \xi = \frac{\lambda}{C}$$

$$\mathcal{L}(w, b, \xi, \lambda) = \frac{1}{2} w^T w + \frac{C}{2} \sum_{i=1}^m \xi_i^2 + \sum_{i=1}^m \lambda_i (1 - y_i(w^T x_i + b)) - \langle \xi, \lambda \rangle \Rightarrow$$

$$\begin{aligned} \mathcal{L}(\lambda) &= \frac{1}{2} \sum_{j=1}^m \sum_{i=1}^m \lambda_j \lambda_i y_i y_j x_i x_j + \frac{C}{2} \left\| \frac{\lambda}{C} \right\|^2 - \frac{\|\lambda\|^2}{C} + \sum_{i=1}^m \lambda_i \\ &\quad - \sum_{j=1}^m \sum_{i=1}^m \lambda_j \lambda_i y_i y_j x_i x_j - b \sum_{i=1}^m \lambda_i y_i \\ &= \sum_{i=1}^m \lambda_i - \frac{\|\lambda\|^2}{2C} - \frac{1}{2} \sum_{j=1}^m \sum_{i=1}^m \lambda_j \lambda_i y_i y_j x_i x_j \end{aligned}$$

(d)

נשים לב שאם  $\sum_{i=1}^m \lambda_i y_i \neq 0$  אז  $\mathcal{L}(\lambda) = -\infty$  לכן הבעיה הדואלית היא :

$$\max_{\lambda} \sum_{i=1}^m \lambda_i - \frac{\|\lambda\|^2}{2C} - \frac{1}{2} \sum_{j=1}^m \sum_{i=1}^m \lambda_j \lambda_i y_i y_j x_i x_j$$

$$s.t: \quad \sum_{i=1}^m \lambda_i y_i \neq 0$$

4. נמצא מיפוי  $\phi$  נגדיר:

$$\phi: [k] \rightarrow \{0,1\}^k, \phi(x) = (1, \dots, 1, 0, \dots, 0) \quad (x \text{ פעמים } 1)$$

$$\phi(x)\phi(y) = \min\{x, y\}$$

5.

יהי  $x, x' \in \mathbb{R}^d$  נתון כי  $K$  גרעין לכן מתקיים

$$k(x, x') = \phi(x)\phi(x')$$

נחזיק מערך  $A$  בגודל  $n$  שהכניסה ה-  $i-1$  מכילה את המקדם של  $\phi(x_i)$


נסמן  $w_0 = \mathbf{0}$  כלומר  $A=[0, \dots, 0]$  לכן  $w_1 = Cy_i \phi(x_{i_1})$  כלומר נעדכן את כניסה ה-  $i_1 - 1$  במערך מאפס ל-  $Cy_i$  ואז  $w_2 = (1 - \eta)w_1 + Cy_{i_2} \phi(x_{i_2})$  לכן צריך להעדכן את הכניסות  $i_1 - 1, i_2 - 1$  לאחר  $t$  צעדים  $w_t = \sum_{i=1}^n A_{i-1} \phi(x_i)$  נשים לב שכל צעד דורש עדכון של לכל היותר  $n$  תאים ובסוף נוכל לחשב  $w^* = \sum_{i=1}^n A_{i-1} \phi(x_i)$  ולבצע סיווג על ידי

$$\text{sign}(w^* x) = \text{sign}\left(\sum_{i=1}^n A_{i-1} \phi(x_i) \phi(x)\right) = \text{sign}\left(\sum_{i=1}^n A_{i-1} k(x_i, x)\right)$$

## חלק מעשי


1.

$a$ ) המסווג עם הגרעין הלינארי:




כפי שניתן לראות הוא מפריד נכון את הדאטה על ידי פונקציה לינארית ומספר הווקטורים התומכים הוא 3

המסווג הריבועי:




רואים שהמסווג הוא פונקציה ריבועית (פרבולות) ושיש 4 וקטורי תמיכה בנוסף הוא נותן צורה לקבוצה הירוקה

מסווג עם גרעין  $RBF$ :




ניתן לראות שהמסווג נותן צורה לשני הקבוצות ושיש שבעה וקטורי תמיכה

(b)




ניתן שרטוטים של  $C = 10^{-2}, 1, 100$  ניתן לראות שככל ש- $C$  נמוך יותר המסווג נותן עדיפות למרחק ההחלטה על גבי סיווג נכון של הנקודות כמו כן ניתן לראות שמ- $C = 100$  התוצאות הדיוק הוא זהה לכן זהו ה- $C$  הטוב ביותר

$C = 10^{-2}$




$C = 1$

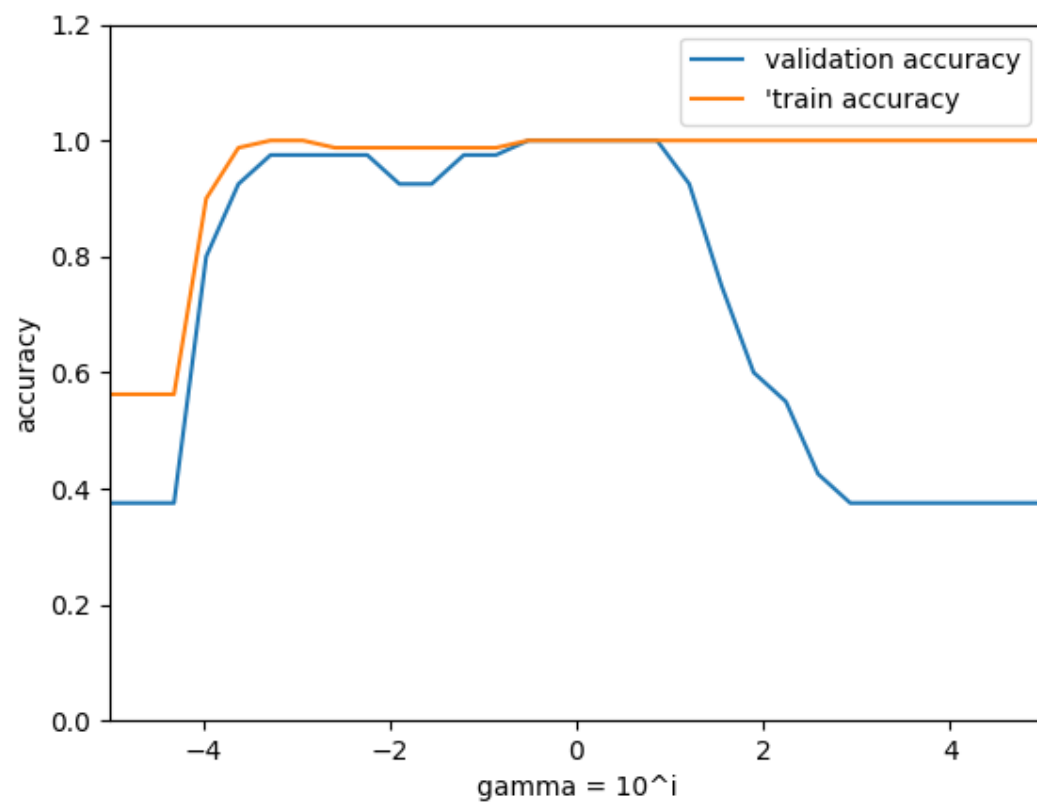




$$C = 100$$




(c)



ניתן לראות שהשגיאה הולכת ומשפרת עד לאיזור  $\gamma = 1$  ולאחר מכן אנו מבצעים אוברפיט על הדאטה


$\gamma = 1$ :




ניתן לראות שהמסווג מיצר צור שכבר ממש הדוקה על הדאטה

$\gamma = 100$ :

על הדאטה האימון



על *validation data*



ניתן לראות שהמסווג ממש הדוק על דאטה האימון ככה שהוא מפספס את *validation data* כלומר שי אובר פיט של המסווג לדאטה האימון.